



知识驱动的流程工业智能制造

桂卫华*, 曾朝晖, 陈晓方*, 谢永芳, 孙玉波

中南大学自动化学院, 长沙 410083

* 通信作者. E-mail: gwh@csu.edu.cn, xiaofangchen@csu.edu.cn

收稿日期: 2020-07-10; 接受日期: 2020-08-28; 网络出版日期: 2020-09-22

国家自然科学基金 (批准号: 61988101, 61773405) 和山东省重大科技创新工程项目 (批准号: 2019JZZY020123) 资助

摘要 智能制造是实现我国流程工业高效化、绿色化、高质量发展的必由之路. 知识是流程工业智能制造的核心要素, 知识驱动的流程工业智能制造是流程制造业发展的新模式. 论文从流程制造业中知识的重要性和特点出发, 综述了知识研究及应用现状. 提出了知识驱动的流程工业智能制造系统框架, 探讨了深度知识获取、知识注入和工业知识图谱等关键技术. 通过铝电解企业智能决策过程应用案例阐明了以上关键技术在流程工业智能制造系统中的重要作用. 最后给出了知识驱动的流程工业智能制造面临的挑战性问题 and 未来展望.

关键词 流程工业, 智能制造, 知识驱动, 工业知识图谱

1 引言

流程工业主要包括石油、化工、钢铁、有色、建材等原材料行业, 是我国国民经济的支柱产业和实体经济发展的根基. 经过数十年发展, 我国已成为世界上门类最齐全、规模最庞大的流程工业制造大国. 目前我国流程制造工业总体工艺技术水平与国外发达国家相当, 部分工艺、设备达到国际先进水平, 但还面临着资源紧缺、能源消耗大、安全环保压力大、技术人力资源短缺等问题. 我国流程工业正从局部调节、粗放操作的生产模式向全流程优化、精细化运行管控的生产模式发展, 但是转型升级还不够充分, 高效化、绿色化成为流程工业可持续发展的主题. 高效化和绿色化生产是指在市场和原料变化的情况下, 通过优化资源配置, 增强工业生产全流程的安全性和可靠性, 提高产品性能、品质和附加值, 实现能源与资源高效利用和污染物近零排放.

在新一代人工智能技术和现代信息技术的发展驱动下, 智能制造是实现我国流程工业高效化、绿色化、高质量发展的必由之路^[1,2]. 智能制造包括生产工艺智能化和生产运行智能化. 生产工艺智能化可以提升工艺设计效率, 提高产品质量和附加值, 从工艺流程上降低物耗、能耗和污染物排放. 生产

引用格式: 桂卫华, 曾朝晖, 陈晓方, 等. 知识驱动的流程工业智能制造. 中国科学: 信息科学, 2020, 50: 1345–1360, doi: 10.1360/SSI-2020-0211
Gui W H, Zeng Z H, Chen X F, et al. Knowledge-driven process industry smart manufacturing (in Chinese). Sci Sin Inform, 2020, 50: 1345–1360, doi: 10.1360/SSI-2020-0211

运行智能化是指在原料、能源、产品等外部市场变化条件下, 以企业全局和生产运行全过程的高效化与绿色化为目的, 使原材料采购、经营决策、计划调度、运行过程参数选择以及生产操作智能化. 对于工艺设计确定的流程工业而言, 生产运行的智能化是智能制造的主要关注问题. 由于流程工业与离散工业存在显著区别^[3,4], 以“工业 4.0”为代表的离散工业智能制造模式不适用于流程工业. 经过数十年的发展, 我国流程工业的信息化已达到一定水平, 但在过程控制、计划调度、经营决策等层面存在智能化程度较低的问题^[5,6]. 为实现流程工业高效化和绿色化, 必须自主创新发展适合我国流程工业的智能制造模式^[7,8].

2 知识是流程工业智能制造的核心要素

2.1 流程制造业中知识的重要性

目前, 我国流程企业采用的信息系统智能化程度低、各层次功能相对独立、集成性还没有完全实现^[9,10]. 流程制造企业各层分别采用具有信息集成和管理功能的企业资源计划 (ERP)、制造执行系统 (MES) 和过程控制系统 (PCS) 等信息系统. ERP 和 MES, MES 和 PCS 间存在知识鸿沟, 导致企业目标、资源计划、调度、运行指标、生产指令与控制指令等各层次决策处于需要知识型工作者结合领域知识、凭借经验人工决策的状态.

知识型工作在流程制造企业中起到核心作用. 如在流程制造企业的各层次决策中, 需要统筹考虑各种生产控制、计划调度和经营管理等要素, 关联跨领域知识, 再由知识型工作者凭经验给出决策. 在过程控制层, 工程师凭借经验知识, 综合工艺机理知识、设备运行数据决定过程控制系统的设定值; 在生产计划和生产调度层, 调度人员根据信息系统提供的原料物流、能源供应和设备管理数据, 结合计划调度专业知识和自身经验, 给出能源资源配置、生产调度、仓储物流、工作排班、设备管理等决策; 在生产经营决策层, 管理决策者根据自身经验和经营管理专业知识, 分析企业内部生产数据、外部市场环境及相关政策、法规、标准等非结构化知识, 制定一系列经营决策. 因此, 在目前的流程制造企业中, 机理知识、经验知识、数据知识并存, 而知识型工作者对这些知识进行关联、融合、分析、判断, 给出决策, 用人工决策填补了 ERP 和 MES, MES 和 PCS 间的知识鸿沟.

由此可见, 目前知识型工作者在流程工业生产中起关键作用, 这是因为人经过学习、训练、思考具有专业知识, 能够运用知识进行复杂分析、精确判断和创新决策, 这体现了知识的核心价值. 流程工业智能制造的实现不能脱离工艺机理知识、过程经验知识和数据挖掘知识, 知识是流程工业智能制造的核心要素.

人工决策方式具有随意性、主观性和不一致性, 难以处理过程控制、运行和生产管理产生的海量数据, 知识难以积累传承. 在过程控制层面, 设备控制指令仍需靠知识型工作者给定, 大多数设备不能实现故障情况下的自愈控制, 反应缓慢, 实时性差; 生产工艺参数选择很难做到最优. 在生产计划和生产调度层面, 由于缺乏生产要素数据的分析认知能力和有效的知识获取应用方法, 人工制定生产计划和调度计划, 随意性大且不够精确; 调度系统与设备控制系统互相独立, 工程师凭经验协调调度与控制指令, 难以做到敏捷调整和优化运行. 在生产经营决策层面, 企业内部的信息系统还不能快速处理多源异构大数据以及不同领域不同层次的关联知识. 特别是当市场需求和生产工况发生频繁变化时, 人工决策方式难以及时准确地调整各项生产运行指标.

对于流程行业而言, 智能制造就是在已有的流程行业物理制造系统基础上, 通过新一代信息技术自动处理、融合和应用机理知识、经验知识和数据知识, 构建知识驱动的智慧型制造执行系统, 实现生

产全流程的智慧决策和集成优化,提升企业在资源利用、能源管理、生产加工和安全环保等方面的技术水平,达到管理决策和生产制造的高效化和绿色化.知识驱动的流程工业智能制造是我国流程工业从根本上实现转型升级和由大变强的必由之路^[2,9,11,12].

2.2 流程制造业中知识的特点

在流程工业中,知识主要包括以下3种:(1)能够反映生产过程物质能量转化传递本质规律的机理知识;(2)反映人对生产过程认知理解的经验知识;(3)隐含在海量数据中反映个性化和实时生产工况的数据知识.

机理知识反映了流程工业生产过程的本质规律,是流程工业最重要、核心的知识,具有形式多样性和异构性的特点.流程生产往往是典型的大规模物质能量转化过程,动态特性复杂,涉及一系列复杂的物理化学反应和固、液、气三相之间的转变.相对于离散制造业来说,流程工业产品和原料品类繁多,生产工艺流程复杂多样,不同产品的制造工艺、装置、工序环节都不相同,涉及不同工艺机理,具有鲜明特点.在现场实验、实验室实验、理论推导等研究工作的基础上得到的机理知识是显性知识,部分机理知识已经被形式化为公式、方程式等数学形式,并随着机理研究深入不断更新.同时,机理知识仍然具有非结构化特点,难以形式化.

经验知识反映了人对于操作与过程之间内在关联的认知,具有隐蔽性、非量化、非一致性的特点.流程工业生产、管理通常需要工艺专家或管理人员依据经验知识进行分析判断,做出决策.由于大多数情况下工艺专家或管理人员的经验知识参差不齐、经验知识丰富的工艺专家或管理人员频繁流动,势必会影响流程企业高效绿色生产.知识型工作者的经验、技巧、诀窍和直觉等都是隐性知识,需要显性化为显性知识并进行验证,这是一个知识创新的过程.显性化后的经验知识可形式化为多种不同知识表示形式,如专家规则、语义网络等.

数据知识是流程工业数据中隐含的知识.流程生产过程数据具有动态性、关联性、多尺度特点.过程数据的动态性反映了流程生产过程中工况、操作和原料等的动态变化.过程数据的动态性表现在两方面:一方面,同一变量在不同时间段的数据分布不同,呈现出不规则的变化;另一方面,不同变量间的关系也在不规则变化.同一流程生产过程的多个变量具有时空关联性.时空关联性数据指的是动态生产过程中获取的具有时空关联特性的多元变量,即其变量不仅在时间上高度相关,在空间上也相互关联.数据的多尺度特点可以满足不同层次决策对数据的需求.数据的多尺度特点体现为在流程生产过程中,生产数据在采集频率上存在很大的不同,呈现出了时间尺度的不一致性.数据知识就隐含在这些具有动态性、关联性和多尺度特点的过程生产数据中;与一般意义上的数据知识相比,流程工业的数据知识往往与工艺机理和生产过程相关,具有更丰富的工艺语义;在流程生产中,一次简单的失误就可能造成严重后果,对数据知识的可靠性有更高的要求,数据知识挖掘的难度大.

2.3 流程制造业中知识研究及应用现状

要实现知识驱动的智能制造,需要从知识获取、处理、应用等方面开展深入研究,前期已经取得了不少成果,为流程工业智能化提供了一定基础.

2.3.1 知识获取

流程工业智能制造的知识获取是指从专家或其他知识来源获取知识并向知识型系统转移的过程;涉及新知识的发现和已知知识的形式化、数值化等.知识获取方法根据知识源不同而不同.知识获取常用的方法主要有规则挖掘法^[13,14]、统计学习方法^[15,16]、深度学习^[17,18]、进化算法^[19,20]、基

于事例的推理方法^[21,22]、基于符号智能或者计算智能方法^[23]等。尽管已有多种知识获取的方法,但是流程工业生产过程与复杂的物理化学反应机理紧密相关,又涉及丰富的经验知识,如何发现并获取更深层次的知识,依然是研究的难点;如何融合机理、经验知识,发现并获取动态性、关联性和多尺度性数据中的隐含知识仍是主要难题;对工业大数据环境下知识发现和获取的研究仍有待深入;各层次决策规则的发现获取等问题仍需解决。

2.3.2 知识处理

流程工业智能制造中的知识表示定义了流程工业中知识的表现形式,知识表示方法依据后期知识处理中所采用的方法不同而不同。当前知识表示常用的方法主要有关联规则表示法^[24,25]、模糊认知图表示法^[26,27]、动态不确定因果图^[28,29]、Petri 网表示法^[30]、语义网络表示^[31]、面向对象表示法^[32]、框架表示法^[33]等。

知识推理作为流程工业知识处理的重要环节,一直备受关注。流程工业知识推理就是利用已知知识推出新知识的过程。流程生产领域常用的知识推理方法有基于贝叶斯网络的知识推理^[34,35]、基于案例的知识推理^[36,37]、基于模糊逻辑的知识推理^[38,39]、基于粗糙集的知识推理^[40]、基于 Petri 网的知识推理^[41]、基于本体的知识推理^[42]等。虽然出现了多种知识推理方法,但是针对流程制造业中知识更深层次的分析仍然有待加强。

目前,已经出现了一批通用和专用知识图谱,如百科知识图谱 Freebase^[43]、DBpedia^[44,45]、YAGO^[46~48]、XLORE; 常识知识图谱 Cyc^[49]、ConceptNet^[50,51] 和中文概念图谱 CN-Probase 等;地理知识图谱 Geonames、医学知识图谱 SIDER、电影知识图谱 IMDB 和音乐知识图谱 MusicBrainz。当前主流的知识图谱数据模型表示方法有 RDF^[52,53] 和属性图^[54,55] 两种。随着知识图谱的出现,很多基于知识图谱的推理方法被提出来。基于规则的推理^[56,57] 和基于本体的推理^[58,59] 借鉴了传统的知识推理方法。基于分布式表示推理^[60~62]、基于神经网络的推理^[63,64]、混合推理^[65,66] 均是研究热点^[67,68]。以流程企业多层决策为应用背景的知识图谱及相关知识推理方法仍然欠缺。

2.3.3 知识应用

许多国际知名的流程行业软件与服务供应商开发了大型流程模拟软件并将其商品化。这些流程行业软件将过程机理知识蕴含在模型、软件和系统中,例如基于炼油行业机理知识开发的 ASPEN-PLUS, ROCESS, HYSYS, PETROFINE 等软件,取得了一定的效果^[69]。虽然国际供应商向我国流程行业提供了这类知识应用软件系统和服务,但是其核心技术和算法保密,在很多场景下适应性存在问题。因此,我国流程工业需要发展具有自主知识产权的关键技术,将机理知识、经验知识和数据知识蕴含在模型、软件和系统中,搭建知识驱动的智能制造软件平台。

3 知识驱动的流程工业智能制造系统框架

流程工业智能制造要实现高效化和绿色化,需要构建知识驱动的流程工业智能制造系统,使其能自动完成原来由知识型工作者完成的知识加工过程,实现流程制造企业各层信息流的无缝连接,为各层次决策、计划调度和生产控制操作等动态调整提供有力支撑。

图 1 是知识驱动的流程工业智能制造系统框架,该框架由 3 大系统和一个平台组成,包括智能感知系统、知识驱动的运行优化—状态监控—虚拟制造系统和智能制造核心软件系统,以及工业大数据管理云平台。同时,还必须研究并实现深度知识获取和知识注入等关键技术,以弥补现有制造系统缺

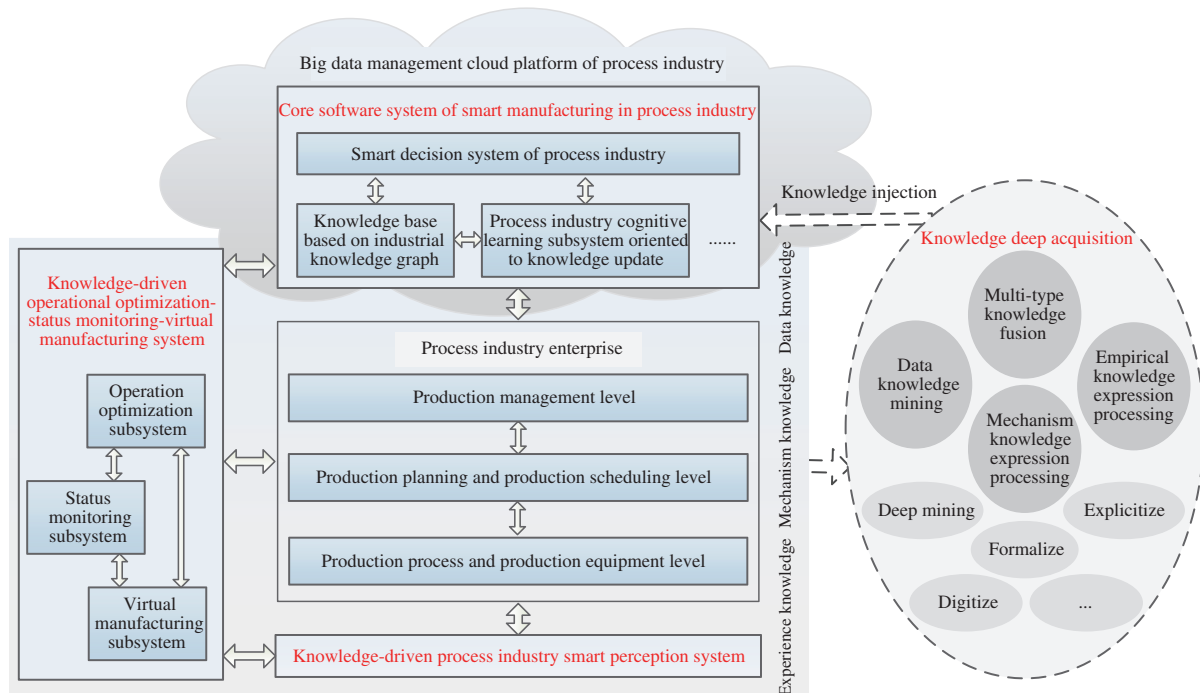


图 1 (网络版彩图) 知识驱动的流程工业智能制造系统框架

Figure 1 (Color online) Framework of knowledge-driven smart manufacturing system of process industry

失工艺机理知识、经验知识的不足, 填补 ERP 和 MES, MES 和 PCS 间的知识鸿沟.

3.1 深度知识获取

流程制造业要实现高效绿色生产, 需要将多类型知识形式化、数值化, 以实现知识在流程工业智能制造系统中的流动. 机理知识是多以文字等非结构化形式出现的显性知识; 经验知识是属于专家或决策者的缄默知识; 而数据知识隐含在流程制造企业各层信息系统中的结构化数据里, 这些知识都与生产工艺紧密相关. 深度知识获取是指结合生产工艺分析, 利用多种方法对经验知识、机理知识和数据知识进行显性化、形式化和挖掘, 最终实现数值化, 得到新知识的过程. 知识注入是指将经过验证是正确的新知识代码化, 注入到流程工业智能制造核心软件系统中. 经验知识经过显性化、形式化和数值化, 机理知识经过形式化和数值化, 数据中隐含的知识经过挖掘后, 得到可注入到流程工业核心软件系统中的新知识. 深度知识获取到的新知识注入到流程工业智能制造核心软件系统后, 与流程工业大数据结合, 在流程工业智能制造系统中流动, 为 3 大系统、一个平台提供知识支撑. 当深度知识获取到的新知识, 注入到核心软件系统中后, 就可以实现大数据环境下流程制造业生产经营过程中知识灵敏感知、自动获取, 进而推动形成流程工业知识自动化的知识源基础, 有助于填补 ERP 和 MES, MES 和 PCS 间的知识鸿沟, 实现高效绿色生产. 因此, 深度知识获取和知识注入必须完成以下工作.

(1) 机理知识的表达与处理. 如何以问题为导向, 在大量非结构化的文字资料中寻找关键机理知识; 如何形式化机理知识是深度知识获取和知识注入必须解决的问题.

(2) 经验知识的表达与处理. 如何从知识型工作者的经验中获取经验知识; 如何识别和验证隐性的经验知识; 如何显性化经验知识是深度知识获取面临的难题.

(3) 数据知识挖掘. 流程工业生产数据是生产设备内部物理化学反应的外在反映, 与工艺机理强相关. 因此, 除了常用的数据挖掘方法, 还需要采用新方法挖掘更深层次的数据知识.

(4) 机理、经验和数据知识融合. 流程工业生产过程的复杂性决定了新知识的发现和验证需要采用融合工艺机理、经验知识和数据知识的知识加工过程, 建立与知识加工过程相匹配的技术体系.

3.2 知识驱动的流程工业智能感知系统

知识驱动的流程工业智能感知系统需要具有在复杂场景中的动态感知能力, 将跨时空多源异构传感数据进行汇集和融合, 利用工艺机理知识、过程经验知识和数据挖掘知识, 通过记忆、学习、判断和推理等多种方法, 智能感知工业设备运行状态, 实现基于知识的多物理场建模, 对反映工况变化的多时空状态参数实现知识驱动的系统集成, 为知识驱动的运行优化—状态监控—虚拟制造系统、流程工业智能制造核心软件系统提供依据. 知识驱动的流程工业智能感知系统主要功能包括: 知识驱动的设备状态参数在线检测; 知识驱动的设备运行状态感知; 基于在线仿真及实测参数关键物理场的软测量; 知识驱动的智能感知系统集成等.

3.3 知识驱动的运行优化—状态监控—虚拟制造系统

该系统由知识驱动的运行优化子系统、状态监控子系统和虚拟制造子系统组成. 其中运行优化子系统是智能决策系统的执行系统, 状态监控子系统可以保证运行优化子系统安全运行和自优化, 虚拟制造子系统可为运行优化提供仿真平台, 为状态监控提供参考.

运行优化子系统需要分析原料供应情况、产品/半成品价格等企业外部环境, 各生产工序中多个或单个生产设备的运行工况数据、图像等企业内部设备能力, 凭借各层知识型工作者的经验、机理知识, 调整综合生产指标、月/日生产指标及各工序/装置的设定值. 知识驱动的运行优化子系统利用深度知识获取和知识注入关键技术快速感知企业外部环境和内部设备能力等的变化, 及时准确地调整各层运行指标、设备设定值, 将运行指标的实际值快速、稳定、精确地控制在目标范围内, 达到提高产品质量、降低生产能耗的目标.

状态监控子系统除了涉及由生产设备产生的多采样频率监视信号, 还涉及大量产品质量和安全、排放泄漏指标等图表数据及质量监视产生的视频和图像数据. 除了以上结构化数据外, 目前的状态监控还涉及由监控人员掌握的对生产运行及其环境指标、产品质量和排放泄漏等安全、异常和事故判断的经验知识. 知识驱动的状态监控子系统利用以上监控信息, 结合深度知识获取和注入到核心软件系统中的新知识, 定期判定待监控对象是否符合标准, 将监控结果反馈给实施监控的对象并对生产动态性能进行评价, 根据评价结果对生产决策控制进行自优化调整, 实现高效绿色安全生产.

虚拟制造子系统需要大量机理知识、实时生产数据、多源传感信息和产品品质指标的支撑, 才能刻画虚拟企业和虚拟实验中物质流、能源流与信息流. 知识驱动的虚拟制造子系统利用从以上机理知识、实时生产数据、多源传感信息和产品品质指标中深度获取并注入到核心软件系统中的知识, 实现知识驱动的工艺设计检测、产品品质预测、制造过程中决策与控制方案评估等功能.

3.4 流程工业智能制造核心软件系统

流程工业智能制造核心软件系统封装了流程工业智能决策系统、基于工业知识图谱的知识库和面向知识更新的流程工业认知学习子系统等核心软件. 其中, 基于工业知识图谱的知识库为智能决策系统提供了完备的知识和数据支撑, 认知学习子系统为智能决策系统提供了丰富的模型和算法支撑.

3.4.1 流程工业智能决策系统

流程工业智能决策系统是智能制造核心软件系统的重要系统,包括知识驱动的智能经营管理决策、计划调度决策和运行优化控制决策等3个子系统.该系统采用人机交互方式,动态决策综合生产经营指标、企业级调度计划和运行指标等.

(1) 知识驱动的智能经营管理决策子系统.知识驱动的智能经营管理决策子系统使用深度知识获取和注入到核心软件系统中的知识,自动、全面、快速地感知企业内部生产、外部生存环境、国家政策变化,对市场变化和生产行为进行实时计算和预测,及时给出可供选择的生产经营决策集合.

(2) 知识驱动的智能计划调度决策子系统.知识驱动的智能计划调度决策子系统使用从信息系统提供的相关数据、计划调度专业知识和高水平知识型工作者的经验知识中深度获取并注入到核心软件系统的知识,自动、全面、准确和快速地制定出企业级生产计划和调度计划、各生产职能部门级调度计划和运行指标.

(3) 知识驱动的智能运行优化控制决策子系统.知识驱动的智能运行优化控制决策子系统使用从生产装置/设备产生的多采样频率信号、信息系统提供的相关数据、工程师经验知识和工艺机理知识中深度获取并注入到核心软件系统的知识,分析生产工况、设备运行状况,依据企业生产计划和运行指标,确定最优生产工艺参数和各装置/设备的设定值.当市场需求和生产工况发生变化时,知识驱动的智能运行优化控制决策子系统能及时准确地给出最优生产工艺参数和各装置/设备的设定值,以做到敏捷调整和优化运行,最终实现提高产品质量、降低生产成本和资源消耗的目标.

3.4.2 基于工业知识图谱的知识库

流程工业智能制造面临如何将复杂多样知识用统一的表达模式表示出来,如何将多时空分布知识纳入统一的知识库模型等问题.

基于工业知识图谱的知识库以提高知识在流程工业智能制造中的利用率为目的,为以上难题提供了一种解决方案.流程工业知识图谱用统一的表达模式,将多样性、碎片化的知识存入统一的知识图谱中,可以满足流程工业对知识需求的多样性.流程工业知识图谱将流程工业的复杂性、流程工序间的关联性导致的流程工业中知识的相互关联性与知识图谱中知识关系的多样性和关联性对应.

与其他领域的知识图谱不同,流程工业知识图谱侧重于决策.目前生产过程中的决策系统面临的最大问题之一就是知识库不够完善,这也是过去决策支持系统只能用于局部、单一、静态问题的原因之一.基于工业知识图谱的知识库除包含现有各层信息系统中的结构化数据外,还包括深度知识获取得到的新知识,实现知识存储的扁平化.流程工业知识图谱为各层次决策模型提供可持续更新、可靠和关联的决策知识,缓解现有信息系统中知识断层和不完备等问题.

3.4.3 面向知识更新的流程工业认知学习子系统

经过数十年的发展,流程工业企业在企业生产经营目标、调度计划、运行指标决策等方面积累了大量优秀的模型、算法等.动态增量式认知学习是知识驱动更新决策能力的重要体现,通过区分知识关联的确定部分和未定部分,从而使每一步自学习增量关联都包含前期的已确定关联,形成知识的有效积累.流程工业认知学习子系统以模型图谱、算法图谱的形式实现企业生产经营目标、调度计划、运行指标决策所需模型、算法的组织管理和更新,实现对模型、算法的快速学习和提取.

4 知识驱动的铝电解智能制造案例

4.1 知识驱动的铝电解智能制造系统框架

目前, 知识型工作在铝电解企业运行中起到核心作用. 工艺工程师、各分厂负责人和总部经营管理者凭借积累的机理知识、经验知识及其他相关知识, 分析铝电解企业 PCS/MES/ERP 等信息系统中存储的数据, 得到各项指标. 在图 2 所示知识驱动的铝电解智能企业中, 深度知识获取将机理知识、经验知识和数据知识经显性化、形式化、深度挖掘和数值化后得到新知识, 验证后存入基于铝电解知识图谱的知识库中. 新知识作为元知识注入到智能制造核心软件系统中, 在核心软件系统中流动.

当知识驱动的铝电解智能决策系统工作时, 从基于铝电解知识图谱的知识库中提取所需参数, 从认知子系统中提取所用模型和算法, 最终给出综合生产经营决策集以辅助铝电解企业集团经营管理者做出决策. 当综合生产经营决策被集团经营管理者确认后, 知识驱动的铝电解智能决策系统再将综合生产经营决策分解为各分厂的调度计划、运行指标和铝电解槽控制箱的设定值.

4.2 深度知识获取和知识注入关键技术应用案例

铝电解过程是以氧化铝为原料, 使直流电通过电解槽上的炭素阳极, 流经熔融冰晶石电解质, 在阴极上得到熔融金属铝并在阳极上析出二氧化碳的过程. 铝电解生产过程涉及多种工艺机理知识, 如氧化铝溶解机理、电解质温度变化机理和氧化铝浓度变化机理, 且关系复杂、相互影响. 铝电解工艺工程师在长期的生产实践中积累了大量生产操作经验. 电解槽控制系统采集并存储了大量历史运行数据, 这些数据虽然是结构简单的时序数据, 但包含了丰富的在线槽况信息. 目前, 工艺工程师采用结合自身经验, 对工艺机理知识、生产运行数据关联、融合、分析和判断的人工决策过程, 确定电解槽控制决策中关键参数槽电压、下料间隔等的设定值.

文献 [70] 给出了一个涉及运行优化子系统中深度知识获取、知识注入关键技术和智能运行优化控制决策过程的应用案例. 该应用案例将机理知识、经验知识和数据知识蕴含在基于表观溶解滞后系数的反馈补偿下料优化控制决策模型中. 该模型能及时感知电解槽内部电解质温度、氧化铝浓度变化, 快速调整电解槽下料间隔的设定值, 将氧化铝浓度稳定、精确地控制在目标范围内. 深度知识获取过程简述如下.

(1) 在长期工业现场调研和大量铝电解槽历史运行数据分析的基础上, 该应用案例得到并显性化表示经验知识“在正常工况时, 电解槽的氧化铝欠量下料、过量下料操作对应了一种固定的槽电压变化规律”, 接着利用相关工艺机理知识对其进行解释和验证.

(2) 在已有工艺机理研究的基础上, 该应用案例分析总结了与氧化铝溶解机理、电解质温度变化机理、氧化铝浓度变化机理、熔体运动机理和电解槽槽电压、下料状态相关的关键工艺机理知识并表示为工艺机理知识 M1~M11.

(3) 利用以上经验知识和工艺机理知识 M1~M11, 该应用案例挖掘 6 种典型槽况对应的下料状态数据和表观氧化铝浓度数据之间隐含的工艺语义, 并给出数值化方案, 得到新知识——表观溶解滞后系数, 实现了多知识融合的新知识发现.

在新知识注入阶段, 通过将深度知识获取过程代码化, 实现了表观溶解滞后系数的自动获取; 接着, 可自动获取的表观溶解滞后系数作为元知识注入到铝电解智能制造核心软件系统, 在核心软件系统中流动. 以下简单介绍表观溶解滞后系数注入到核心软件系统后的两个应用.

(1) 在线槽况识别. 通过对多工况下大量表观溶解滞后系数的系统性分析, 该应用案例还发现: 使用表观溶解滞后系数不仅有助于在线识别电解质温度变化, 还有助于在线检测氧化铝浓度异常. 与斜

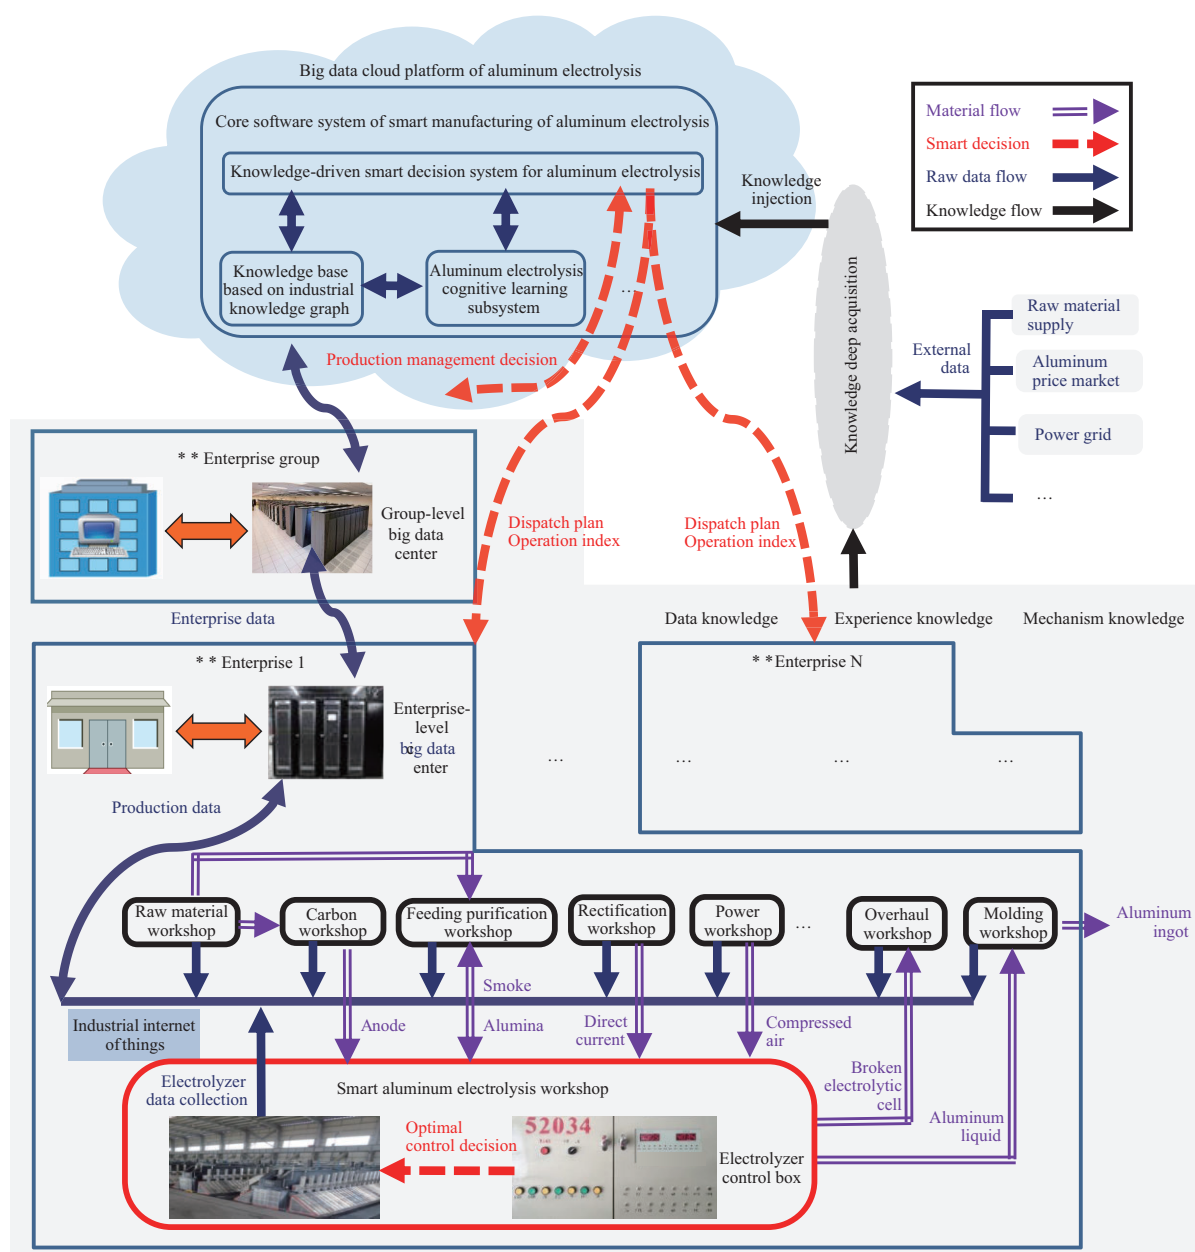


图 2 (网络版彩图) 知识驱动的流程工业智能制造系统在铝电解企业中的应用

Figure 2 (Color online) Application of knowledge-driven smart manufacturing system in aluminum electrolysis enterprises

率法相比, 使用表观溶解滞后系数不仅能提前检测到氧化铝浓度异常低工况, 还能检测到斜率法较难检测到的浓度异常高工况。

表观溶解滞后系数的设计过程使用了融合工艺机理知识、经验知识和数据知识的深度知识获取关键技术, 使得表观溶解滞后系数本身就蕴含了特定的工艺语义。因此, 使用表观溶解滞后系数进行电解质温度和氧化铝浓度识别, 具有成本低、通用性好、计算代价小、可解释性和可复现性好等优点。

在图 2 所示知识驱动的铝电解智能制造系统中, 电解质温度和氧化铝浓度的识别算法存于铝电

解认知学习子系统的算法图谱中。表观溶解滞后系数作为元知识存于基于铝电解知识图谱的知识库中。

(2) 下料优化控制决策。该应用案例还给出了基于表观溶解滞后系数的反馈补偿下料优化控制决策模型。该下料优化控制决策模型有如下特点: (1) 在线电解质温度信息参与下料控制; (2) 表观溶解滞后系数的引入形成了下料反馈补偿控制回路; (3) 与斜率法相比, 基于表观溶解滞后系数的氧化铝浓度异常检测, 可优化下料间隔的设定值, 且算法简单。因此, 基于表观溶解滞后系数的反馈补偿下料优化控制决策模型, 对尽早稳定槽况、提高电流效率有较大帮助, 是现有槽控机控制系统的有益补充。

当使用该下料优化控制决策模型时, 知识驱动的铝电解智能决策系统到认知学习子系统的算法图谱中提取“在线浓度识别”和“在线温度识别”等算法, 到基于铝电解知识图谱的知识库中提取所需参数, 确定最优的下料控制规则和下料补偿规则。当电解质温度、氧化铝浓度等发生较大变化时, 知识驱动的智能运行优化控制决策子系统能及时准确地给出下料控制规则和下料补偿规则中关键参数的改变值。当外部环境发生变化时, 知识驱动的铝电解智能决策系统辅助铝电解企业集团经营管理者调整生产经营决策、各分厂的运行指标、各智能铝电解车间的生产运行指标, 最终给出各铝电解槽槽电压等关键参数的设定值, 做到敏捷调整和优化运行。

5 结论

5.1 面临的问题

知识驱动的流程工业智能制造系统从流程制造企业中深度获取知识, 并将获取的新知识注入到流程工业智能制造核心软件系统中, 数据和知识在核心软件系统流动的过程中对该框架的有效性、准确性、实时性等进行验证, 得到不断更新完善的知识体系。知识驱动的流程工业智能制造系统仍然面临如下问题。

(1) 流程工业知识的复杂多样性对知识自动获取处理提出挑战。流程工业智能制造相关知识具有复杂多样性。这些知识跨物理、化学、材料、控制、管理、数学等多个领域, 主要包括工艺机理知识、经验知识和数据知识, 这 3 种知识的载体各不相同, 且是分离的。例如操作决策知识对长流程生产过程来说跨多个生产环节, 具有多目标决策性质, 过去这些知识必须将操作者的主观判断、分析、决策行为联系起来。而流程工业智能制造决策软件系统要实现知识的自动分析和处理, 知识关系越复杂难度越大。如何通过深度知识获取产生新知识, 如何构建具有一定解析深度的知识关系模型, 将工业过程机理、人的经验知识、数据特征和操作规则统一起来, 形成具有知识自动获取处理能力的核心软件系统, 是具有挑战性的难点之一。

(2) 流程工业动态不确定环境与知识模型结构化存在对立。流程工业智能制造面临的问题往往不是静态的数学建模问题, 必须面对复杂多变的动态环境, 不确定因素多。以决策为例, 在知识获取层面上, 面对的是多环节跨领域的动态知识和不完备碎片化的隐性知识; 在知识应用层面上, 环境具有动态不确定性, 无法精确建模, 各环节的决策需要协同。现有的决策支持系统的知识结构固定, 难以适应动态多变的实际决策环境。因此利用深度知识获取和知识注入技术, 构建具有动态知识关联和认知学习能力的流程工业知识图谱, 建立自治自治的流程工业智能制造核心软件系统, 解决动态不确定环境与知识模型结构化之间的矛盾, 是具有挑战性的难点之二。

(3) 面向流程制造的人机物融合混合智能增强机制有待研究。人机协同的混合增强智能是《新一

代人工智能发展规划》部署的5个重要方向之一。在流程工业中,领域专家和操作工程师已经积累了丰富的决策经验知识,但这些知识还是静态、孤立、片面地存在于人脑中,与智能制造数据环境、动态的物理生产体系脱节,缺乏人机混合增强的协同机制。而单纯的机器智能不可避免地存在操作失误和失控的风险,而且早期不可靠、不完备,需要人的介入和干预,必须依靠向人学习实现双向协同。从长期运行来看,智能制造系统不是为了摆脱人,而是为了使人类智能和机器智能各擅所长,各尽其用,人类决策者在人机物融合的智能制造环境中始终拥有最终决策权和监督权。因此,如何在流程制造环境下实现人机协同决策、人机互学习、混合增强智能的人-信息-物理融合机制是具有挑战性的难点之三。

5.2 未来展望

为了让新一代信息技术赋能流程制造,实现知识驱动的流程工业智能制造,未来需要发展智能性、软件生态和支撑环境等方面的关键技术和系统。

(1) 知识驱动的智能自主决策核心技术。为提高经营管理、计划调度、运行控制的效率、精准度和自动化水平,需要将工艺机理知识、过程经验知识和数据挖掘知识深度融入各层决策模型,并能够自主认知、主动学习、动态更新各层次决策模型,使智能自主决策系统具有敏捷性、鲁棒性与可解释性的优点。

(2) 流程工业智能制造软件生态体系。工业4.0、智能自主决策、智能制造等新理念与技术归根到底要落实到软件系统的形态上,工业软件正从产品、技术、业务形态、产业发展模式等多维度重塑工业体系,现代工业从“以装备为核心的工业”向“以软件定义的工业”转变。流程工业需要发展的自主工业软件主要是工业控制软件、智能决策软件、数字孪生仿真软件和智能运维管理软件等。

(3) 基于工业互联网的新一代信息技术支撑平台。随着云计算、大数据、物联网、人工智能、移动通信等ICT技术的飞速发展及其与流程制造业的深度融合,基于工业互联网的新一代信息技术支撑平台对流程企业和信息技术企业均会带来变革性影响。工业互联网信息平台将流程企业甚至跨企业的人、机、物连接成一个整体,打破信息与知识孤岛,形成资源统筹协调的优化配置支撑平台。不仅如此,面向行业的工业互联网平台还将产业链中各环节的连接变得更加紧密,不仅能提升企业获利空间,而且能够在产业技术、客户需求和业务模式上推动协同创新,促成新技术、新思维、新业态的发展。

参考文献

- 1 Chai T Y. Industrial process control systems: research status and development direction. *Sci Sin Inform*, 2016, 46: 1003–1015 [柴天佑. 工业过程控制系统研究现状与发展方向. *中国科学: 信息科学*, 2016, 46: 1003–1005]
- 2 Qian F, Gui W H. Boosting optimization and upgrade for manufacturing industry by artificial intelligence. *Bull National Natural Sci Found China*, 2018, 3: 257–261 [钱锋, 桂卫华. 人工智能助力制造业优化升级. *中国科学基金*, 2018, 3: 257–261]
- 3 Gui W H, Wang C H, Xie Y F, et al. The necessary way to realize great-leap-forward development of process industries. *Bull National Natural Sci Found China*, 2015, 5: 337–342 [桂卫华, 王成红, 谢永芳, 等. 流程工业实现跨越式发展的必由之路. *中国科学基金*, 2015, 5: 337–342]
- 4 Lee J, Singh J, Azamfar M, et al. Industrial AI: a systematic framework for AI in industrial applications. *China Mech Eng*, 2020, 31: 37–48 [李杰, Singh J, Azamfar M, et al. 工业人工智能 —— 工业应用中的人工智能系统框架. *中国机械工程*, 2020, 31: 37–48]

- 5 Ding J L, Yang C E, Chen Y D, et al. Research progress and prospects of intelligent optimization decision making in complex industrial process. *Acta Autom Sin*, 2018, 44: 1931–1943 [丁进良, 杨翠娥, 陈远东, 等. 复杂工业过程智能优化决策系统的现状与展望. *自动化学报*, 2018, 44: 1931–1943]
- 6 Wang Y. Research on production planning and scheduling under uncertainty. Dissertation for Ph.D. Degree. Hangzhou: Zhejiang University, 2016 [王越. 不确定环境下生产计划和调度的研究. 博士学位论文. 杭州: 浙江大学, 2016]
- 7 Qian F, Du W L, Zhong W M, et al. Problems and challenges of smart optimization manufacturing in petrochemical industries. *Acta Autom Sin*, 2017, 43: 893–901 [钱锋, 杜文莉, 钟伟民, 等. 石油和化工行业智能优化制造若干问题及挑战. *自动化学报*, 2017, 43: 893–901]
- 8 Sun C Y, Zhou J W. Smart and optimal manufacturing development strategy for mineral processing industry. *Non-ferrous Metals (Mineral Process Section)*, 2019, 5: 1–5 [孙传尧, 周俊武. 流程工业选矿过程智能优化制造发展战略. *有色金属 (选矿部分)*, 2019, 5: 1–5]
- 9 Cai T Y, Ding J L, Gui W H, et al. Research on the Development Strategy of Big Data and Manufacturing Process Knowledge Automation. Beijing: China Science Press, 2019 [柴天佑, 丁进良, 桂卫华, 等. 大数据与制造流程知识自动化发展战略研究. 北京: 科学出版社, 2019]
- 10 Gui W H, Yue W C, Xie Y F, et al. Review of intelligent optimal manufacturing for aluminum reduction production. *Acta Autom Sin*, 2018, 44: 39–52 [桂卫华, 岳伟超, 谢永芳, 等. 铝电解生产智能优化制造研究综述. *自动化学报*, 2018, 44: 39–52]
- 11 Wang F Y. The destiny: towards knowledge automation—preface of the special issue for the 50th anniversary of *Acta Automatica Sinica*. *Acta Autom Sin*, 2013, 39: 1741–1743 [王飞跃. 天命唯新: 迈向知识自动化 ——《自动化学报》创刊 50 周年专刊序. *自动化学报*, 2013, 39: 1741–1743]
- 12 Gui W H, Chen X F, Yang C H, et al. Knowledge automation and its industrial application. *Sci Sin Inform*, 2016, 46: 1016–1034 [桂卫华, 陈晓方, 阳春华, 等. 知识自动化及工业应用. *中国科学: 信息科学*, 2016, 46: 1016–1034]
- 13 Park H, Jung J Y. SAX-ARM: deviant event pattern discovery from multivariate time series using symbolic aggregate approximation and association rule mining. *Expert Syst Appl*, 2020, 141: 112950
- 14 Zhang B, Yang C, Zhu H, et al. Controllable-domain-based fuzzy rule extraction for copper removal process control. *IEEE Trans Fuzzy Syst*, 2018, 26: 1744–1756
- 15 Yang C H, Zhou L F, Huang K K, et al. Multimode process monitoring based on robust dictionary learning with application to aluminium electrolysis process. *Neurocomputing*, 2019, 332: 305–319
- 16 Wang H, Lin N, Jing S. Supporting knowledge uncertainty engineering-knowledge acquisition. *Comput Integr Manuf Syst*, 2015, 21: 2558–2563
- 17 Xie S W, Xie Y F, Huang T, et al. Generalized predictive control for industrial processes based on neuron adaptive splitting and merging RBF neural network. *IEEE Trans Ind Electron*, 2019, 66: 1192–1202
- 18 Martinsen K, Downey J, Baturynska I. Human-machine interface for artificial neural network based machine tool process monitoring. *Procedia CIRP*, 2016, 41: 933–938
- 19 Huang Z K, Yang C H, Chen X F, et al. Adaptive over-sampling method for classification with application to imbalanced datasets in aluminum electrolysis. *Neural Comput Applic*, 2020, 32: 7183–7199
- 20 Bi W, Dandy G C, Maier H R. Improved genetic algorithm optimization of water distribution system design by incorporating domain knowledge. *Environ Model Softw*, 2015, 69: 370–381
- 21 Reyes E R, Negny S, Robles G C, et al. Improvement of online adaptation knowledge acquisition and reuse in case-based reasoning: application to process engineering design. *Eng Appl Artif Intell*, 2015, 41: 1–16
- 22 Rintala L, Leikola M, Sauer C, et al. Designing gold extraction processes: performance study of a case-based reasoning system. *Miner Eng*, 2017, 109: 42–53
- 23 Gao Z, Cecati C, Ding S X. A survey of fault diagnosis and fault-tolerant techniques—Part II: fault diagnosis with

- knowledge-based and hybrid/active approaches. *IEEE Trans Ind Electron*, 2015, 62: 3768–3774
- 24 Kamsu-Foguem B, Rigal F, Mauget F. Mining association rules for the quality improvement of the production process. *Expert Syst Appl*, 2013, 40: 1034–1045
 - 25 Yu X, Huang D, Jiang Y, et al. Iterative learning belief rule-base inference methodology using evidential reasoning for delayed coking unit. *Control Eng Practice*, 2012, 20: 1005–1015
 - 26 Yue W, Gui W, Chen X, et al. A data and knowledge collaboration strategy for decision-making on the amount of aluminum fluoride addition based on augmented fuzzy cognitive maps. *Engineering*, 2019, 5: 1060–1076
 - 27 Lima N M N, Liñan L Z, Manenti F, et al. Fuzzy cognitive approach of a molecular distillation process. *Chem Eng Res Des*, 2011, 89: 471–479
 - 28 Dong C, Zhou Z, Zhang Q. Cubic dynamic uncertain causality graph: a new methodology for modeling and reasoning about complex faults with negative feedbacks. *IEEE Trans Rel*, 2018, 67: 920–932
 - 29 Li L, Yue W. Dynamic uncertain causality graph based on Intuitionistic fuzzy sets and its application to root cause analysis. *Appl Intell*, 2020, 50: 241–255
 - 30 Wang W M, Peng X, Zhu G, et al. Dynamic representation of fuzzy knowledge based on fuzzy petri net and genetic-particle swarm optimization. *Expert Syst Appl*, 2014, 41: 1369–1376
 - 31 Zhang Y, Luo X, Buis J J, et al. LCA-oriented semantic representation for the product life cycle. *J Cleaner Production*, 2015, 86: 146–162
 - 32 Terletskyi D. Inheritance in object-oriented knowledge representation. In: *Information and Software Technologies*. Berlin: Springer International Publishing, 2015. 293–305
 - 33 Minsky M. A framework for representing knowledge. *Readings Cogn Sci*, 1974, 76: 156–189
 - 34 Yue W C, Chen X F, Gui W H, et al. A knowledge reasoning fuzzy-Bayesian network for root cause analysis of abnormal aluminum electrolysis cell condition. *Front Chem Sci Eng*, 2017, 11: 414–428
 - 35 Diallo T M L, Henry S, Ouzrout Y. Bayesian network building for diagnosis in industrial domain based on expert knowledge and unitary traceability data. *IFAC-PapersOnLine*, 2015, 48: 2411–2416
 - 36 Yan A, Wang W, Zhang C, et al. A fault prediction method that uses improved case-based reasoning to continuously predict the status of a shaft furnace. *Inf Sci*, 2014, 259: 269–281
 - 37 Han M, Cao Z J. An improved case-based reasoning method and its application in endpoint prediction of basic oxygen furnace. *Neurocomputing*, 2015, 149: 1245–1252
 - 38 Ding J, Cao Y, Mpofu E, et al. A hybrid support vector machine and fuzzy reasoning based fault diagnosis and rescue system for stable glutamate fermentation. *Chem Eng Res Des*, 2012, 90: 1197–1207
 - 39 Cao D Y, Zeng S P, Li J H. Variable universe fuzzy expert system for aluminum electrolysis. *Trans Nonferrous Met Soc China*, 2011, 21: 429–436 [曹丹阳, 曾水平, 李晋宏. 面向铝电解槽的变论域模糊专家系统. *中国有色金属学报*, 2011, 21: 429–436]
 - 40 Maji P, Garai P. IT2 fuzzy-rough sets and max relevance-max significance criterion for attribute selection. *IEEE Trans Cybern*, 2015, 45: 1657–1668
 - 41 Yue W C, Gui W H, Chen X F, et al. Knowledge representation and reasoning using self-learning interval type-2 fuzzy Petri nets and extended TOPSIS. *Int J Mach Learn Cyber*, 2019, 10: 3499–3520
 - 42 Roda F, Musulin E. An ontology-based framework to support intelligent data analysis of sensor measurements. *Expert Syst Appl*, 2014, 41: 7914–7926
 - 43 Bollacker K, Evans C, Paritosh P, et al. Freebase: a collaboratively created graph database for structuring human knowledge. In: *Proceedings of the ACM SIGMOD International Conference on Management of Data*. New York: ACM Press, 2008. 1247–1250
 - 44 Auer S, Bizer C, Kobilarov G, et al. DBpedia: a nucleus for a web of open data. In: *Proceedings of the 6th International*

- Semantic Web Conference. Berlin: Springer, 2007. 722–735
- 45 Bizer C, Lehmann J, Kobilarov G, et al. DBpedia—a crystallization point for the web of data. *J Web Semant*, 2009, 7: 154–165
- 46 Suchanek F M, Kasneci G, Weikum G, et al. Yago: a core of semantic knowledge. In: *Proceedings of the 16th International Conference on World Wide Web*, 2007. 697–706
- 47 Hoffart J, Suchanek F M, Berberich K, et al. YAGO2: a spatially and temporally enhanced knowledge base from Wikipedia. *Artif Intell*, 2013, 194: 28–61
- 48 Mahdisoltani F, Biega J, Suchanek F. Yago3: a knowledge base from multilingual Wikipedias. In: *Proceedings of the 7th Biennial Conference on Innovative Data Systems Research (CIDR)*, 2014
- 49 Lenat D B. CYC: a large-scale investment in knowledge infrastructure. *Commun ACM*, 1995, 38: 33–38
- 50 Speer R, Havasi C. Representing general relational knowledge in ConceptNet 5. In: *Proceedings of the International Conference on Language Resources and Evaluation*, 2012. 3679–3686
- 51 Speer R, Chin J, Havasi C. ConceptNet 5.5: an open multilingual graph of general knowledge. In: *Proceedings of the 31st AAAI Conference on Artificial Intelligence*, 2017. 4444–4451
- 52 Gallagher B. Matching structure and semantics: a survey on graph-based pattern matching. In: *Proceedings of AAAI Fall Symposium: Capturing and Using Patterns for Evidence Detection*, 2006. 6: 45–53
- 53 Wylot M, Hauswirth M, Cudré-Mauroux P, et al. RDF data storage and query processing schemes. *ACM Comput Surv*, 2018, 51: 1–36
- 54 The Neo4j Team. The Neo4j Manual v3.4. 2018. <https://neo4j.com/docs/developer-manual/current/>
- 55 Angles R, Arenas M, Barceló P. G-CORE: a core for future graph query languages. In: *Proceedings of the 2018 International Conference on Management of Data*. Houston: ACM, 2018. 1421–1432
- 56 Jang S, Megawati M, Choi J, et al. Semi-automatic quality assessment of linked data without requiring ontology. In: *Proceedings of the International Semantic Web Conference (ISWC)*. Berlin: Springer-Verlag, 2015. 45–55
- 57 Wang W Y, Mazaitis K, Lao N, et al. Efficient inference and learning in a large knowledge base. *Mach Learn*, 2015, 100: 101–126
- 58 Pujara J, Miao H, Getoor L, et al. Knowledge graph identification. In: *Proceedings of the 12th International Semantic Web Conference*. Berlin: Springer-Verlag, 2013. 542–557
- 59 Chen Y, Goldberg S, Wang D Z, et al. Ontological pathfinding: mining first-order knowledge from large knowledge bases. In: *Proceedings of the 2016 ACM SIGMOD International Conference on Management of Data*. New York: ACM Press, 2016. 835–846
- 60 Jiang T, Liu T, Ge T, et al. Towards time-aware knowledge graph completion. In: *Proceedings of the 26th International Conference on Computational Linguistics*. Stroudsburg: ACL, 2016. 1715–1724
- 61 Tay Y, Luu A T, Hui S C. Non-parametric estimation of multiple embeddings for link prediction on dynamic knowledge graphs. In: *Proceedings of the 31st AAAI Conference on Artificial Intelligence*, Menlo Park, 2017. 1243–1249
- 62 Feng J, Huang M, Yang Y, et al. GAKE: graph aware knowledge embedding. In: *Proceedings of the 26th International Conference on Computational Linguistics*. Stroudsburg: ACL, 2016. 641–651
- 63 Shi B, Weninger T. ProjE: embedding projection for knowledge graph completion. In: *Proceedings of the 31st AAAI Conference on Artificial Intelligence*, Menlo Park, 2017. 1236–1242
- 64 Graves A, Wayne G, Reynolds M, et al. Hybrid computing using a neural network with dynamic external memory. *Nature*, 2016, 538: 471–476
- 65 Schlichtkrull M S, Kipf T, Bloem P, et al. Modeling relational data with graph convolutional networks. In: *Proceedings of European Semantic Web Conference*, 2018. 593–607
- 66 Yang F, Yang Z, Cohen W W, et al. Differentiable learning of logical rules for knowledge base reasoning. In: *Proceedings*

- of Neural Information Processing Systems, 2017. 2316–2325
- 67 Guan S P, Jin X L, Jia Y T, et al. Knowledge reasoning over knowledge graph: a survey. *J Softw*, 2018, 29: 2966–2994 [官赛萍, 靳小龙, 贾岩涛, 等. 面向知识图谱的知识推理研究进展. *软件学报*, 2018, 29: 2966–2994]
- 68 Wang S, Du Z J, Meng X F, et al. Research progress of large-scale knowledge graph completion technology. *Sci Sin Inform*, 2020, 50: 551–575 [王硕, 杜志娟, 孟小峰. 大规模知识图谱补全技术的研究进展. *中国科学: 信息科学*, 2020, 50: 551–575]
- 69 Huang D X, Jiang Y H, Jin Y H. Present research situation, major bottlenecks, and prospect of refinery industry process control. *Acta Autom Sin*, 2017, 43: 902–916 [黄德先, 江永亨, 金以慧. 炼油工业过程控制的研究现状, 问题与展望. *自动化学报*, 2017, 43: 902–916]
- 70 Zeng Z H, Gui W H, Chen X F, et al. A mechanism knowledge-driven method for identifying the pseudo dissolution hysteresis coefficient in the industrial aluminium electrolysis process. *Control Eng Practice*, 2020, 102: 104533

Knowledge-driven process industry smart manufacturing

Weihua GUI*, Zhaohui ZENG, Xiaofang CHEN*, Yongfang XIE & Yubo SUN

School of Automation, Central South University, Changsha 410083, China

* Corresponding author. E-mail: gwh@csu.edu.cn, xiaofangchen@csu.edu.cn

Abstract Smart manufacturing is a necessary approach to realize highly efficient, green, and high-quality development of China's process industry. Knowledge is the core production factor of smart manufacturing in the process industry, where knowledge is a new mode of innovation in process industry development. Based on the importance and characteristics of knowledge in process manufacturing, this paper reviews the research and application of knowledge in process manufacturing. A systematic framework of knowledge-driven process industry smart manufacturing is proposed, and crucial technologies, such as knowledge deep acquisition, knowledge injection, and industrial knowledge graph, are discussed. Using a case study of the smart decision-making process of aluminum electrolysis enterprises, the important role of the above crucial technologies in the process industry smart manufacturing system is presented. Further, the challenges and future prospects of knowledge-driven process industry smart manufacturing are provided.

Keywords process industry, smart manufacturing, knowledge-driven, industrial knowledge graph



Weihua GUI was born in 1950. He received his M.S. degree in control engineering from Central South University, Changsha, China, in 1984. Currently, he is an academician at the Chinese Academy of Engineering and a professor at Central South University. His research interests include modeling and optimal control of complex industrial processes and industrial large system control theory and application.



Zhaohui ZENG was born in 1977. She received her M.S. degree in computer software and theory from Xiangtan University, Xiangtan, China, in 2007. Currently, she is pursuing her Ph.D. degree from Central South University. Her research interests include knowledge automation and industrial big data analysis.



Xiaofang CHEN was born in 1975. He received his Ph.D. degree in control science and engineering from Central South University, Changsha, China, in 2004. Currently, he is a professor at Central South University. His research interests include intelligent modeling and optimal control of complex industrial processes and knowledge-driven manufacturing.



Yongfang XIE was born in 1972. He received his Ph.D. degree in control science and engineering from Central South University, Changsha, China, in 1999. Currently, he is a full professor at Central South University. He was a recipient of the China National Funds for Distinguished Young Scientists. His research interests include modeling and optimal control of complex industrial processes, distributed robust control, and knowledge automation.